

A3_ComponentesPrincipales

Josue Salvador Cano Martinez

2022-10-11

```
# Matriz de datos
x1 = c(2.5, 0.5, 2.2, 1.9, 3.1, 2.3, 2, 1, 1.5, 1.1)
x2 = c(2.4, 0.7, 2.9, 2.2, 3.0, 2.7, 1.6, 1.1, 1.6, 0.9)
M <- data.frame(x1, x2)
print (M)
```

```
##      x1  x2
## 1  2.5 2.4
## 2  0.5 0.7
## 3  2.2 2.9
## 4  1.9 2.2
## 5  3.1 3.0
## 6  2.3 2.7
## 7  2.0 1.6
## 8  1.0 1.1
## 9  1.5 1.6
## 10 1.1 0.9
```

```
# Creación de matriz con dos columnas que contiene los datos de los registros
```

```
# Matriz de datos centrados en sus medias
meanX1 = c(rep(mean(x1), 10))
meanX2 = c(rep(mean(x2), 10))

M1 <- data.frame(meanX1, meanX2)
M1 = M - M1
print(M1)
```

```
##      x1  x2
## 1  0.69 0.49
## 2 -1.31 -1.21
## 3  0.39 0.99
## 4  0.09 0.29
## 5  1.29 1.09
## 6  0.49 0.79
## 7  0.19 -0.31
## 8 -0.81 -0.81
## 9 -0.31 -0.31
## 10 -0.71 -1.01
```

```
# Se resta a cada valor la media de la variable a la que pertenece. Con esto se consigue centralizar las variables y que su media sea 0
```

```
# Matriz de varianza-covarianza de la matriz de datos centrados  
mcov = cov(M1)  
print(mcov)
```

```
##           x1           x2  
## x1 0.6165556 0.6154444  
## x2 0.6154444 0.7165556
```

```
# Se calcula la matriz de correlaciones entre cada par de variables. Debido a que hay dos variables el resultado es una matriz simétrica de 2x2
```

```
# Valores propios y vectores propios de la matriz de varianza-covarianza de la matriz de datos centrados  
val = eigen(mcov)$values  
print(val)
```

```
## [1] 1.2840277 0.0490834
```

```
vec =eigen(mcov)$vectors  
print(vec)
```

```
##           [,1]      [,2]  
## [1,] 0.6778734 -0.7351787  
## [2,] 0.7351787  0.6778734
```

```
# Debido a que la matriz de covarianzas es cuadrada, es posible calcular sus correspondientes eigenvalues y eigenvectors
```

```
# Matriz traspuesta de los vectores propios y matriz traspuesta de datos centrados  
t_v = t(vec)  
print(t_v)
```

```
##           [,1]      [,2]  
## [1,] 0.6778734 0.7351787  
## [2,] -0.7351787 0.6778734
```

```
t_M1 = t(M1)  
print(t_M1)
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10]
## x1 0.69 -1.31 0.39 0.09 1.29 0.49 0.19 -0.81 -0.31 -0.71
## x2 0.49 -1.21 0.99 0.29 1.09 0.79 -0.31 -0.81 -0.31 -1.01
```

Producto de la matriz transpuesta de los vectores propios con la transpuesta de la matriz de datos centrados

```
CP = t_v%*%t_M1
rownames(CP)= c("CP1", "CP2")
t(CP)
```

```
##              CP1              CP2
## [1,] 0.82797019 -0.17511531
## [2,] -1.77758033 0.14285723
## [3,] 0.99219749 0.38437499
## [4,] 0.27421042 0.13041721
## [5,] 1.67580142 -0.20949846
## [6,] 0.91294910 0.17528244
## [7,] -0.09910944 -0.34982470
## [8,] -1.14457216 0.04641726
## [9,] -0.43804614 0.01776463
## [10,] -1.22382056 -0.16267529
```

El proceso en que se multiplicaron los eigenvectors transpuestos por los datos originales centrados y también transpuestos dio lugar a obtener los componentes principales. Lo que se observa abajo es el valor que toma cada componente para cada observación en función de las variables originales (principal component scores)

```
cpa <- prcomp(M, scale=TRUE)
names(cpa)
```

```
## [1] "sdev"      "rotation" "center"   "scale"    "x"
```

```
print(cpa)
```

```
## Standard deviations (1, .., p=2):
## [1] 1.3877785 0.2721594
##
## Rotation (n x k) = (2 x 2):
##              PC1              PC2
## x1 -0.7071068 0.7071068
## x2 -0.7071068 -0.7071068
```

Reducción de la dimensionalidad de las variables, se tienen dos, por lo que se puede deducir que hay un componente que explica la varianza de las dos variables.

```
print("desviaciones estándar: ")
```

```
## [1] "desviaciones estándar: "
```

```
cpa$sdev
```

```
## [1] 1.3877785 0.2721594
```

```
print("medias: ")
```

```
## [1] "medias: "
```

```
print("center y scale dan las medias y desv estándar previa estandarización: ")
```

```
## [1] "center y scale dan las medias y desv estándar previa estandarización: "
```

```
cpa$center
```

```
##    x1    x2  
## 1.81 1.91
```

```
cpa$scale
```

```
##          x1          x2  
## 0.7852105 0.8464960
```

```
print("Los coeficientes de la combinación lineal normalizada de componente")
```

```
## [1] "Los coeficientes de la combinación lineal normalizada de componente"
```

```
cpa$rotation
```

```
##          PC1          PC2  
## x1 -0.7071068 0.7071068  
## x2 -0.7071068 -0.7071068
```


```
print("Los datos por sustituidos en la combinación lineal de vectores propios:")
```

```
## [1] "Los datos por sustituidos en la combinación lineal de vectores propios:"
```


```
cpa$x
```

```
##           PC1           PC2
## [1,] -1.03068029  0.21205314
## [2,]  2.19045016 -0.16894230
## [3,] -1.17818776 -0.47577321
## [4,] -0.32329464 -0.16119898
## [5,] -2.07219947  0.25117173
## [6,] -1.10117414 -0.21865330
## [7,]  0.08785251  0.43005447
## [8,]  1.40605089 -0.05281009
## [9,]  0.53811824 -0.02021127
## [10,] 1.48306451  0.20430982
```

```
biplot(x = cpa, scale = 0, cex = 0.6, col = c("green", "purple"))
```



```
barplot(cpa$sdev^2, col = c("red", "blue"))
```



La gráfica de dispersión permite apreciar hacia qué componente pertenece cada registro

```
summary(cpa)
```

```
## Importance of components:
##               PC1      PC2
## Standard deviation    1.388 0.27216
## Proportion of Variance 0.963 0.03704
## Cumulative Proportion 0.963 1.00000
```

De acuerdo con la proporción de varianza explicada, el 96.3% de la varianza de los datos está integrada en el componente 1