


A8_SeriesDeTiempoNoEstacionariasTendencia

Josue Salvador Cano Martinez

2022-11-21

Gráfico de dispersión

```
t <- c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16)
ventas = c(4.8, 4.1, 6, 6.5, 5.8, 5.2, 6.8, 7.4, 6, 5.6, 7.5, 7.8, 6.3, 5.9, 8, 8.4)
plot(t, ventas, type = "o", col = "red", main = "Dispersión de ventas")
```



Se observa que cada año las ventas disminuyen en el segundo trimestre, y aumentan en el tercero y cuarto trimestre. Por tanto, se concluye que en la venta de estos televisores hay un comportamiento estacional

Análisis de tendencia y estacionalidad

```
x= ts(ventas, frequency = 4, start=c(2016,1)))
T = decompose(x)
T
```


```

## $x
##   Qtr1 Qtr2 Qtr3 Qtr4
## 1  4.8  4.1  6.0  6.5
## 2  5.8  5.2  6.8  7.4
## 3  6.0  5.6  7.5  7.8
## 4  6.3  5.9  8.0  8.4
##
## $seasonal
##           Qtr1           Qtr2           Qtr3           Qtr4
## 1 -0.4395833 -1.0687500  0.5895833  0.9187500
## 2 -0.4395833 -1.0687500  0.5895833  0.9187500
## 3 -0.4395833 -1.0687500  0.5895833  0.9187500
## 4 -0.4395833 -1.0687500  0.5895833  0.9187500
##
## $trend
##   Qtr1  Qtr2  Qtr3  Qtr4
## 1    NA    NA 5.4750 5.7375
## 2 5.9750 6.1875 6.3250 6.4000
## 3 6.5375 6.6750 6.7625 6.8375
## 4 6.9375 7.0750    NA    NA
##
## $random
##           Qtr1           Qtr2           Qtr3           Qtr4
## 1           NA           NA -0.06458333 -0.15625000
## 2  0.26458333  0.08125000 -0.11458333  0.08125000
## 3 -0.09791667 -0.00625000  0.14791667  0.04375000
## 4 -0.19791667 -0.10625000           NA           NA
##
## $figure
## [1] -0.4395833 -1.0687500  0.5895833  0.9187500
##
## $type
## [1] "additive"
##
## attr(,"class")
## [1] "decomposed.ts"

plot(T, col ="blue")

```

Decomposition of additive time series




Se puede notar que la tendencia tiene un aumento a lo largo del tiempo, mientras que la estacionalidad denota una variación estacional de las ventas siguiendo una constante aleatoriedad.

Modelo lineal de la tendencia

```
# Regresión lineal de la tendencia
ventas_desestacionalizadas = (T$x)/(T$seasonal)
x3 = 1:16
y3 = ventas_desestacionalizadas
N3 = lm(y3~x3)
N3

##
## Call:
## lm(formula = y3 ~ x3)
##
## Coefficients:
## (Intercept)          x3
##      5.1080         0.1474

plot(x3, y3, type = "l", xlab = "Trimestre", ylab = "Ventas")
abline(N3, col = "red")
text(6, 7, "ventas = 5.1080 + 0.1474 trimestre")
```



```
# Pertinencia del modelo lineal
summary(N3)
```

```
##
## Call:
## lm(formula = y3 ~ x3)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.5007 -0.1001  0.0037  0.1207  0.3872
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.10804    0.11171   45.73  < 2e-16 ***
## x3           0.14738    0.01155   12.76 4.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.213 on 14 degrees of freedom
## Multiple R-squared:  0.9208, Adjusted R-squared:  0.9151
## F-statistic: 162.7 on 1 and 14 DF,  p-value: 4.248e-09
```

Significancia de β_1

Hipótesis

$$H_0: \beta_i = 0$$

$$H_1: \beta_i \neq 0$$

Regla de decisión

Se rechaza H_0 si: * Si el valor p es menor a $\alpha = 0.05$

Conclusión

El valor de p-value es 4.25e-9, menor a alpha, por lo que la hipótesis nula se rechaza.

Variabilidad explicada por el modelo

```
cat("Coeficiente de Determinacion:", summary(N3)$r.squared, "\n")
```

```
## Coeficiente de Determinacion: 0.9207911
```

El coeficiente de determinación dice que la variabilidad explicada por el modelo es de 92.07%.

Prueba de normalidad y análisis de residuos

1. Hipótesis

H_0 : Los datos representan una población normal

H_1 : Los datos no representan una población normal

2. Regla de decisión

Se rechaza H_0 si valor $p < \alpha$ donde $\alpha = 0.05$

3. Analisis de Resultados

```
sha = shapiro.test(N3$residuals)
cat("p-vaule:", sha$p.value, "\n")
```


```
## P-vaule: 0.7306976
```

4. Conclusión

No se rechaza H_0 , los datos provienen de una población normal.

```
E=N3$residuals
Y=N3$fitted.values
```

```
qqnorm(E)
qqline(E,col="red")
```



La gráfica anterior demuestra un comportamiento normal de los residuos.

CME y EPAM

```
n = 0
e = NA
prediction = NA

for (i in ventas_desestacionalizadas){
  n = n + 1
  prediction[n] = 5.1080 + (0.1474 * n)

  e[n] = (i - prediction[n])
}

CME=mean(e^2,na.rm = TRUE)
EPAM = mean(abs(e) / ventas)

cat("CME =", CME)

## CME = 0.03970642

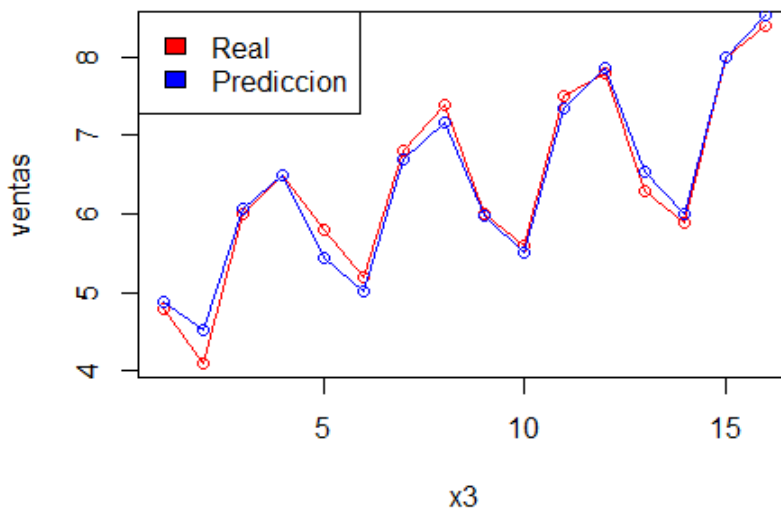
cat("\nEPAM =", EPAM * 100, "%")

##
## EPAM = 2.641619 %
```

Valores de las ventas y las predicciones vs el tiempo

```
plot(x3, ventas, type="o", col="red")
lines(x3, prediction * T$seasonal, type="o", col="blue")

legend(x = "topleft", legend = c("Real", "Prediccion"), fill = c("red", "
blue"))
```



Conclusión del modelo

La variabilidad explicada por el modelo es de 92%, betha es significativo y los residuos presentan normalidad, pudiendo concluir que se trata de un buen modelo, corroborado por la precisión de las predicciones.

Pronóstico para el siguiente año.

```
aux = 0
n2 = 17:20
year5 = NA
for(i in n2){
  aux = aux + 1
  year5[aux] = 5.1080 + (0.1474 * i)
}
pronostico = data.frame(
  "Trimestre" = 1:4,
  "Pronostico" = year5 * T$seasonal[1:4]
)
pronostico
```

##	Trimestre	Pronostico
## 1	1	7.085872
## 2	2	6.491284
## 3	3	8.632585
## 4	4	9.195263

Un problemilla más

Promedios móviles de cuatro trimestres y promedios móviles centrados

```
ventas = c(1690, 940, 2625, 2500, 1800, 900, 2900, 2360, 1850, 1100, 2930, 2615)
p = NA
n = length(ventas)
for(i in 1:(n-3)){
  p[i] = (ventas[i] + ventas[i+1] + ventas[i+2] + ventas[i+3]) / 4;
}
cat("Promedios moviles de cuatro trimestres: \n", p)

## Promedios moviles de cuatro trimestres:
## 1938.75 1966.25 1956.25 2025 1990 2002.5 2052.5 2060 2123.75

pmc = NA
n = length(p)
for(i in 1:(n-1)){
  pmc[i] = (p[i]+p[i+1]) / 2;
}
cat("Promedios moviles centrados: \n", pmc)

## Promedios moviles centrados:
## 1952.5 1961.25 1990.625 2007.5 1996.25 2027.5 2056.25 2091.875
```

Indices estacionales de los cuatro trimestres

```
vei = NA
n = length(pmc)
for(i in 1:n){
  vei[i] = ventas[i+2] / pmc[i];
}

vce = matrix(NA, nrow=4, ncol=2)
n = length(vei)
for(i in 1:n){
  vce[((i+1)%4) + 1, ((i-1)%4) + 1] = vei[i]
}

indices = rowMeans(vce)
df = data.frame(
  "Trimestre" = 1:4,
  "Indice" = indices
)
df
```


##	Trimestre	Indice
## 1	1	0.9019673
## 2	2	0.4870814
## 3	3	1.3985770
## 4	4	1.2193462

¿Cuándo obtiene la editorial el mayor índice estacional?, ¿Parece razonable este resultado?, ¿Por qué?

En el tercer trimestre, es razonable debido a las fechas de inicio de ciclos escolares (tercer trimestre del año) y los estudiantes compran más material académico, entre ellos libros.